

# TITULO MODULO 3 AWS ACADEMY FUNDAMENTOS DE MACHINE LEARNING

NOMBRE: JAVIER DAZA, WILLINGTON RIZZO

CARRERA: INGENIERIA INFORMATICA ASIGNATURA: MACHINE LEARNING

PROFESOR:

FECHA: 22-09-2025



# Objetivo del módulo

### 1.1.1 Objetivo del módulo y del grupo

En primer lugar, el objetivo principal del módulo fue aprender cómo se entrena un modelo supervisado binario (0 y 1) que nos ayude a predecir si un paciente tiene anomalías en la columna o si está sano/normal.

En segundo lugar, como grupo nos propusimos seguir familiarizándonos con la plataforma de AWS, en especial con el servicio SageMaker, y también aprender y explorar las ventajas de usar notebooks para este tipo de tareas.

Para cumplir con estos objetivos, lo que hicimos fue:

- Importar el dataset con las variables biomecánicas y la clase (normal/anormal).
- Preparar los datos, separándolos en entrenamiento, validación y prueba.
- Almacenarlos en S3 en sus respectivos tres archivos.
- Entrenar el modelo supervisado en SageMaker.
- Finalmente, evaluar el modelo (como parte de los pasos de este y los siguientes labs).

### Dataset utilizado

Usamos el dataset de la columna vertebral (Vertebral Column Dataset) proveniente del repositorio UCI Machine Learning. Este conjunto de datos contiene 310 registros y 7 columnas (6 características + 1 variable objetivo).



#### Las columnas son:

- pelvic incidence
- pelvic tilt
- lumbar lordosis angle
- sacral slope
- pelvic radius
- degree spondylolisthesis
- class (etiqueta binaria: Normal o Abnormal)

Este dataset se descarga automáticamente al iniciar el laboratorio de AWS Academy en **Amazon SageMaker**, por lo que fue provisto directamente como parte de la práctica (no es creado por nosotros).

Elegimos este dataset porque es **idóneo para los primeros pasos en aprendizaje supervisado binario**. Su tamaño reducido y su claridad didáctica permiten enfocarse en comprender el **flujo de trabajo completo de Machine Learning**: importar datos, prepararlos, dividirlos en entrenamiento/validación/prueba, cargarlos en S3 y entrenar un modelo.

Además, resulta útil para el objetivo del módulo: **predecir si un paciente tiene anomalías en la columna o si es normal**, lo que conecta con un problema de negocio o investigación en el área de la salud.

Es importante decir que cada uno de los 3 data set que salieron del principar los pusimos en S3 para que pueda alimentar el entrenameinto, validación y test.

## Entrenamiento en SageMaker

Una de las etapas más importantes en este trabajo es el **entrenamiento**, ya que aquí es donde aplicamos el algoritmo que nos permite obtener el modelo final. El algoritmo utilizado fue **XGBoost**, ejecutado en **Amazon SageMaker**.

Durante el entrenamiento se configuraron algunos **hiperparámetros**. Estos son valores que no se aprenden de los datos, sino que se establecen antes de entrenar para guiar cómo aprende el modelo. Entre los que usamos están:

### ADMINISTRACIÓN Y NEGOCIOS

# **I**Inacap

- objective = binary:logistic → indica que el problema es de clasificación binaria (0 = normal, 1 = anormal).
- eval\_metric = auc -> define que el rendimiento se mida con AUC, una métrica estándar para clasificación binaria.
- num\_round = 42 → cantidad de iteraciones de entrenamiento.

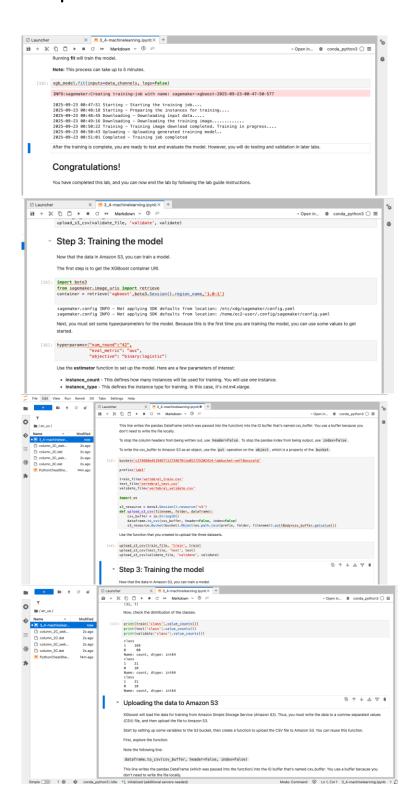
Estos hiperparámetros son importantes porque permiten ajustar el comportamiento del algoritmo, mejorar el rendimiento y evitar problemas como sobreajuste o bajo rendimiento.

El entrenamiento se realizó en una instancia **ml.m4.xlarge**, que es adecuada para este tipo de tareas porque ofrece un equilibrio entre capacidad de cómputo (CPU, memoria) y costo, suficiente para manejar datasets de tamaño mediano como este.

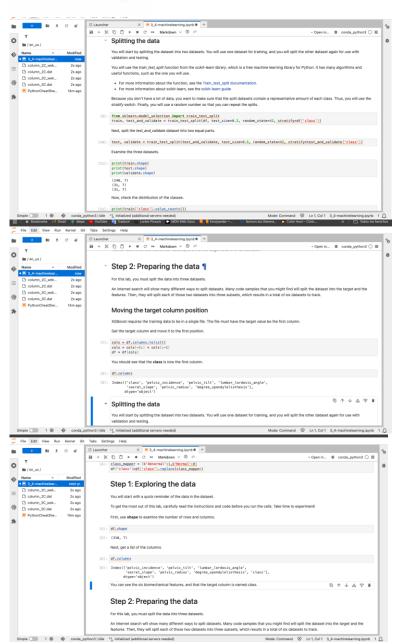
El proceso de entrenamiento tomó aproximadamente **5 minutos**, lo cual es un tiempo normal en SageMaker. Esto ocurre porque el sistema debe preparar los recursos en la nube, ejecutar todas las rondas de entrenamiento y luego guardar el modelo en S3.



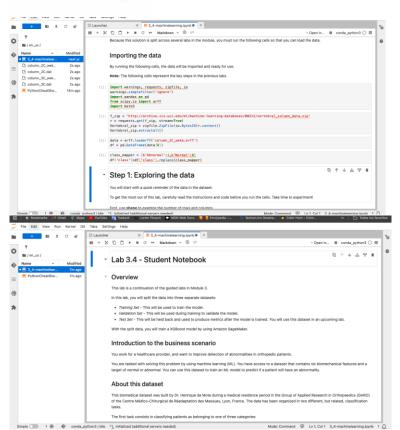
# Capturas de evidencia

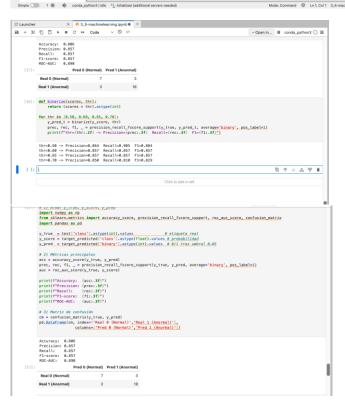




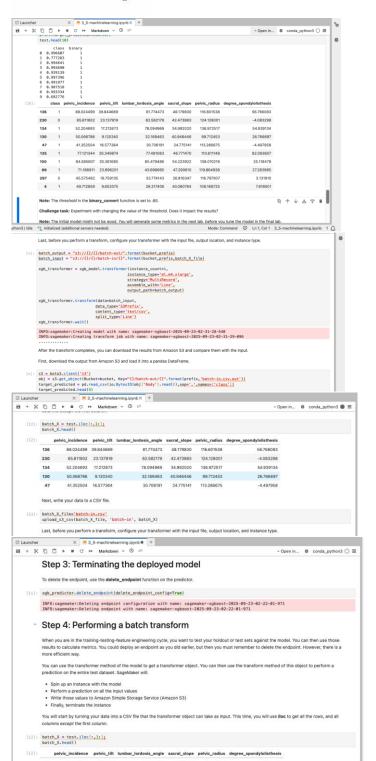




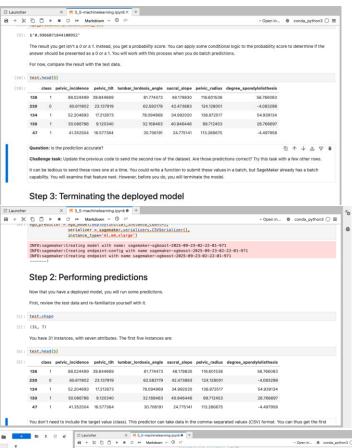


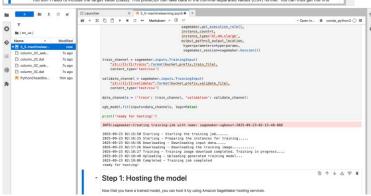
















## Resultados obtenidos

Como se puede ver en las capturas, el **entrenamiento se completó** después de aproximadamente 5 **minutos**. Durante este proceso preparamos los datos, los cargamos en S3 y realizamos el entrenamiento en SageMaker. Al final, el trabajo terminó con éxito, generando un **modelo entrenado listo para ser utilizado** y posteriormente **evaluado mediante métricas de desempeño**.

Tabla de métricas principales (umbral 0.65):



MétricaValorAccuracy0.806Precision0.857Recall0.857F1-score0.857ROC-AUC0.890

#### Ejemplo de predicciones:

- Probabilidad para una muestra: 0.9966 → Predicción = 1 (Anormal)
- Matriz de confusión (umbral 0.65):
  - o Normales bien clasificados (True Negatives): 7
  - o Normales mal clasificados (False Positives): 3
  - o Anormales mal clasificados (False Negatives): 3
  - o Anormales bien clasificados (True Positives): 18

Además, se generaron gráficas de desempeño:

- **Curva ROC:** AUC = 0.890
- Curva Precision–Recall: AP = 0.944
- Matriz de confusión en heatmap

### Discusión

#### Interpretación de resultados:

- El modelo logró una buena capacidad de discriminación (AUC cercano a 0.9).
- Tanto la precisión como el recall son altos (0.857), lo que indica un buen equilibrio entre evitar falsos positivos y falsos negativos.
- El F1-score confirma este balance, mostrando que el modelo es consistente en ambas métricas.

#### Limitaciones del modelo:

- El dataset es relativamente pequeño (310 instancias en total, con solo 31 para test), lo que puede limitar la generalización.
- El modelo solo fue entrenado y evaluado con datos ya preparados, sin mayor exploración de hiperparámetros avanzados.
- No se consideraron técnicas de validación cruzada, lo cual podría dar una visión más robusta del desempeño.

#### Posibles mejoras:



- Ampliar el dataset con más ejemplos clínicos para evitar sobreajuste.
- Ajustar hiperparámetros de XGBoost (como max\_depth, learning\_rate, n\_estimators) con un grid search o random search.
- Probar otros algoritmos supervisados (Random Forest, SVM, Redes Neuronales) y comparar su rendimiento.
- Aplicar validación cruzada y técnicas de balanceo si en versiones futuras se detecta desbalance entre clases.

### Conclusión

- En este módulo se aprendió a entrenar, desplegar y evaluar un modelo supervisado en Amazon SageMaker, utilizando un dataset biomédico de columna vertebral.
- Se comprobó el flujo completo de ML en la nube: carga de datos en S3, entrenamiento con XGBoost, despliegue en un endpoint, predicciones y evaluación de métricas.
- El modelo mostró un rendimiento adecuado (AUC = 0.890, F1 = 0.857), siendo una buena base para aplicaciones de diagnóstico automático.
- Aplicaciones potenciales: este tipo de modelo puede usarse como apoyo clínico para identificar pacientes con posibles anormalidades en la columna, agilizando diagnósticos preliminares y priorización de casos.

### Referencias

Aws

https://us-east-1.console.aws.amazon.com/sagemaker/home?region=us-east-1#/notebooks-and-git-repos